

# Компьютерное зрение с использованием реальных данных

## 1 Введение

Компьютерное зрение является одной из наиболее динамично развивающихся областей искусственного интеллекта, находящей применение в самых разных сферах — от автономных транспортных средств до медицинской диагностики. Однако успешное применение моделей компьютерного зрения в реальных условиях часто осложняется наличием шума и искажений в данных, что требует разработки нечувствительных к шуму архитектур и методов обучения, способных эффективно работать с неидеальными входными данными. В данной работе мы исследуем возможности различных архитектур нейронных сетей и функций потерь для обработки реальных данных на примере датасета CIFAR-10N, который включает как чистые, так и зашумлённые изображения.

CIFAR-10N [25] представляет собой модификацию классического датасета CIFAR-10, где часть данных intentionally искажена для имитации реальных условий, в которых модели могут сталкиваться с шумом, артефактами или ошибками аннотации. В рамках исследования мы рассматриваем три архитектуры: классическую сверточную нейронную сеть (CNN) с настройками, соответствующими экспериментам Xia и соавторов [26], глубокую residual-сеть (ResNet50) и трансформер для изображений (Vision Transformer, ViT). Для обучения моделей используются три вида функций потерь: кросс-энтропия (Cross-Entropy, CE), бинарная кросс-энтропия (Binary Cross-Entropy, B) и функция потерь, учитывающая шум в данных (Noise-Aware Loss, N).

Цель работы — провести сравнительный анализ и эксперименты эффективности выбранной архитектуры и функций потерь в условиях работы с чистыми и зашумлёнными данными, а также выявить наиболее устойчивые подходы для задач классификации в реальных сценариях. Результаты исследования могут быть полезны для разработки моделей, способных сохранять высокую точность даже в условиях значительного уровня шума.

## 2 Проведённая работа

**Обучение с использованием аннотаций реальных людей.** Обучение моделей с зашумлёнными метками является важной проблемой в глубинном обучении, особенно при работе с реальными аннотациями, содержащими ошибки. Датасет CIFAR-10N был создан специально для изучения этого аспекта, так как он включает реальные ошибки, допущенные аннотаторами, что делает задачу борьбы с шумом особенно актуальной.

Были рассмотрены две статьи, имеющие непосредственное отношение к данной теме: [26] и [22]. Первая статья предлагает детальное исследование проблемы обучения с зашумлёнными метками, используя датасет CIFAR-10N, и анализирует влияние различных стратегий очистки данных и методов дообучения модели для повышения её устойчивости к шуму. Авторы рассматривают несколько методов, таких как использование функций потерь, устойчивых к шуму, включая Forward Loss Correction, Backward Loss Correction и Symmetric Cross-Entropy, которые корректируют градиенты в зависимости от вероятности ошибок аннотации. Также исследуются методы фильтрации данных. Авторы показывают, что наиболее эффективными стратегиями являются комбинация устойчивых к шуму функций потерь и методов фильтрации, а также использование частично контролируемого обучения, позволяющего повысить точность модели даже при высоком уровне шума.

Вторая статья представляет обзор методов обучения с зашумлёнными метками, классифицируя их на три основные группы: методы обработки данных (data-centric approaches), методы модификации модели (model-centric approaches) и методы, основанные на функциях потерь (loss-centric approaches). Среди рассмотренных методов в категории обработки данных выделяются Bootstrapping и Label Smoothing, позволяющие корректировать метки за счёт усреднения предсказаний модели, а также Meta-Learning Approaches, которые обучают модель находить оптимальные коэффициенты для борьбы с шумом. В категории функций потерь выделяются Generalized Cross-Entropy, которая снижает влияние выбросов в метках за счёт сочетания квадратичной и стандартной кросс-энтропии, а также Self-Adaptive Training, позволяющий модели самостоятельно определять, какие примеры считать шумными, и адаптировать процесс обучения. Авторы данной статьи предлагают систематизированный обзор методов, который помогает выбрать оптимальную стратегию в зависимости от уровня шума и доступных данных. Однако данная работа носит в основном

теоретический характер и не предоставляет конкретных экспериментов с CIFAR-10N, что делает её менее прикладной по сравнению с первой.

**Учитывание неопределённостей.** Одним из подходов к оценке неопределённости регрессионных моделей является гетероскедастическая (heteroscedastic) регрессия, которая учитывает как среднее значение переменной, так и дисперсию [18, 20]. Таким образом, модель обучается прогнозированию средних значений и дисперсий, и неопределённость прогнозов модели может быть оценена с использованием значений дисперсии. К счастью, модели классификации также могут использовать squared error (SE) loss. Хо и Белкин [10] продемонстрировали, что визуальные модели, основанные на SE и CE функциях потерь, близки по точности. Тем не менее, SE loss требует чуть больше эпох обучения. Кендалл и Гал [11] рассмотрели два типа неопределённости: алеаторическая (неопределённость данных) и эпистемологическая (неопределённость модели), и предложили два подхода к оценке неопределённости. Кендалл и Гал [11] заявили, что примеры, основанные на отсутствии данных, нельзя отождествлять с алеаторической неопределённостью. Авторы также предложили подход, сочетающий алеаторическую и эпистемологическую неопределённость. Дальнейшая работа ван Амерсфорта и других [23] посвящена методу количественной оценки детерминированной неопределённости. Предлагаемая модель изучает положения центроидов классов и обучает ядра оценивать расстояние между входной выборкой и центроидами, что позволяет модели логического вывода распознавать выборку, в которой отсутствуют данные, как неопределённую. Сенсой и другие [21] разработали теорию доказательной базы и представили предсказания модели в виде распределения плотности Дирихле по выходным данным (softmax outputs), а также предложили новую функцию потерь. Коллиер и другие [3] предложили метод обучения глубоких классификаторов в условиях гетероскедастического шума меток (label noise). Метод основан на softmax temperature tuning, которая позволяет контролировать соотношение смещения и дисперсии.

**Ансамблирование, test-time augmentation и label smoothing.** Ашуха и другие [1] продемонстрировали, что многие методы создания ансамблей моделей эквивалентны ансамблю из нескольких независимо обученных сетей с точки зрения производительности тестирования. Test-time augmentation - это метод, который улучшает производительность модели с помощью усреднения прогнозов [14]. Вероятно, самыми простыми способами повысить устойчивость моделей к шуму в метках является label smoothing [24] и аугментирование данных [19].

**Оценка неопределённости данных на практике** Искажённые входные данные [13] и искажённые метки [27], распределения в области определения и вне её [15, 11, 3] являются одними из полюсов исследований в области оценки неопределённости данных. Типичными тестами моделей на практике является использование общедоступных наборов данных с повреждёнными (зашумлёнными) метками на этапах обучения и валидации, но с чистыми метками на этапе тестирования [26, 27]. Существует ряд методов, направленных на выявление входных сэмплов с неправильными метками и удаление [3, 26, 27] или занижение веса этих сэмплов [11, 4]. Хан и другие [8] заявили, что модели сначала изучают данные с чистыми метками, а затем с зашумлёнными, и предложили новую парадигму под названием co-teaching с обучением двух сетей.

### 3 Методология

В общем, рассмотрим модель  $f[\mathbf{x}, \mathbf{w}]$  параметризованную по весам  $\mathbf{w}$ , которая сначала сопоставляет входные значения  $\mathbf{x}$  к логитам  $\mathbf{z}$ , а затем гипотезу  $\mathbf{h}$ , которая аппроксимирует ground truth  $\mathbf{y}$ . The negative log-likelihood minimization [18, 2, 6] позволяет формализовать следующие функции потерь с учетом неопределённости для задач подбора и классификации с использованием различных типов распределений для выходных данных моделей.

#### 3.1 B-loss

В этом параграфе представлена интерпретация модели бинарной классификации, основанной на минимизации *uncertainty-aware negative log-likelihood с распределением Бернулли* (B-model, B-loss). Предлагаемая модель обучена таким образом, что истинные прогнозы становились определёнными, а ложные прогнозы, если они имеют место, - неопределёнными (см. fig. 1). Бинарный классификатор оценивает значение определённости  $s \in (0, 1)$ , что является основной задачей в предлагаемой формализации. Кроме того, классификатор оценивает и усиливает сходство  $\delta$  между гипотезой  $\mathbf{h}$  и ground truth  $\mathbf{y}$ , что составляет вторую задачу в предлагаемой формализации.

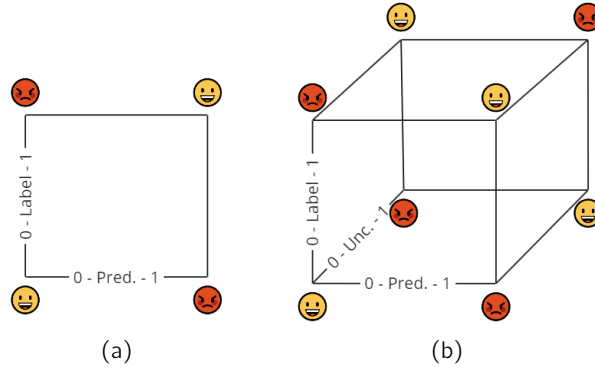


Рис. 1: Основа бинарной классификации с BCE loss (a) и предложенный бинарный B-loss eq. (4) (b) по отношению к значениям выходных данных модели (неопределённости  $u = 1 - c$ , предсказания  $h$ ), и метки  $y$ .

**Бинарная классификация.** Рассмотрим  $i^{\text{th}}$  сэмпл и модель с логитами  $z^{(i)} = [z_{pred}^{(i)}, z_{cert}^{(i)}]$  которые соответствуют предсказанию  $h^{(i)} = \sigma(z_{pred}^{(i)})$ , и достоверность  $c_i = \sigma(z_{cert}^{(i)})$ , связанную с предсказанием, соответственно. Затем сравним предсказание  $h^{(i)}$  и данную метку  $y^{(i)}$ , используя метрику скалярного произведения  $\delta_i = y^{(i)} h^{(i)}$ , и сопоставим эту метрику как псевдомаркировку бинарной оценки неопределённости с параметрами массовой функции вероятности Бернулли [18]:

$$p_i = p(\delta_i | c_i) = \begin{cases} 1 - c_i & \text{if } \delta_i \rightarrow 0, \\ c_i & \text{if } \delta_i \rightarrow 1, \end{cases} \quad (1)$$

где  $\delta_i \in (0, 1)$  - сглаженная псевдомаркировка, которая характеризует сходство между меткой и предсказанием.

eq. (1) представляет собой дискретное распределение вероятности для случайной величины, которая принимает значение 0 с вероятностью  $1 - c_i$ , которая является неверным прогнозом, соответствующим неопределённости прогноза, и значением 1 с вероятностью  $c_i$ , которая является правильным предсказанием, соответствующим достоверности предсказания. Распределение Бернулли имеет эквивалентную форму степенного закона [18]:

$$p_i = c_i^{\delta_i} (1 - c_i)^{1 - \delta_i}. \quad (2)$$

Для roll-out датасета из  $m$  и пар  $\{x^{(i)}, y^{(i)}\}$ , связанных с выходными данными модели  $\{h^{(i)}, c_i\}$ , совместная вероятность [2] для заданной функции массы вероятности eq. (2) принимает следующую форму:

$$P(\delta_1, \dots, \delta_m | c_1, \dots, c_m) = \prod_{i=1}^m c_i^{\delta_i} (1 - c_i)^{1 - \delta_i}. \quad (3)$$

Отрицательный логарифм совместной вероятности eq. (3) представляет предложенный uncertainty-aware B-loss для бинарной классификации:

$$\mathcal{L}_B = -\frac{1}{m} \sum_{i=1}^m [\delta_i \log c_i + (1 - \delta_i) \log(1 - c_i)]. \quad (4)$$

Интуиция eq. (4) продемонстрирована на fig. 1. B-loss может быть обобщен для случая многоклассовой классификации.

**Мультиклассовая (N-classes) классификация.** Рассмотрим  $i^{\text{th}}$  сэмпл и модель с логитами  $\mathbf{z}^{(i)} = [\mathbf{z}_{pred}^{(i)}, z_{cert}^{(i)}]$ , которые соответствуют вектору предсказаний  $\mathbf{h}^{(i)} = \text{softmax}(\mathbf{z}_{pred}^{(i)})$ ,  $\mathbf{h}^{(i)} \in \mathcal{R}^N$ , и достоверность  $c_i = \sigma(z_{cert}^{(i)})$  связанную с предсказаниями, соответственно. Затем сравним вектор предсказаний  $\mathbf{h}^{(i)}$  и данный one-hot encoded label vector  $\mathbf{y}^{(i)}$ , используя термины скалярного произведения  $\delta_k^{(i)} = y_k^{(i)} h_k^{(i)}$ , и сопоставим эти показатели в виде псевдомаркировок с функцией массы вероятности:

$$p_i = \prod_{k=1}^N \left( \frac{c_i}{N} \right)^{\delta_k^{(i)}} \left( \frac{1 - c_i}{N} \right)^{1 - \delta_k^{(i)}}, \quad (5)$$

где  $\delta_k^{(i)} \in (0, 1)$  - сглаженная one-hot encoded псевдомаркировка, которая характеризует сходство между  $k^{\text{th}}$  компонентами метки и вектором предсказаний,  $N$  - количество классов.

Следуя логической последовательности, приведенной в section 3.1 и в [18], совместная вероятность для eq. (5) может быть получена, а затем преобразована в negative log-likelihood (NNL):

$$NLL = -\frac{1}{m} \sum_{i=1}^m \left( \cos(\mathbf{h}^i, \mathbf{y}^i) \log \left( \frac{c^{(i)}}{N} \right) + (N-1) (1 - \cos(\mathbf{h}^i, \mathbf{y}^i)) \log \left( \frac{1 - c^{(i)}}{N} \right) \right), \quad (6)$$

где  $\cos(\mathbf{h}^i, \mathbf{y}^i)$  - сглаженная псевдометка, характеризующая косинусное сходство между двумя  $N$ -мерными векторами: вектор предсказания и вектор метки с one-hot encoding.

Наконец, предложенные uncertainty-aware B-loss для  $N$ -классовой классификации является расхождением Кульбака-Леберга между двумя распределениями: распределение сглаженных псевдометок one-hot encoding и распределение NNL eq. (6):

$$\mathcal{L}_B = \frac{1}{m} \sum_{i=1}^m \sum_{k=1}^N \delta_k^{(i)} \log \delta_k^{(i)} + NLL. \quad (7)$$

где  $m$  - количество сэмплов (в батче),  $N$  - количество классов,  $\delta_i = y^{(i)} h^{(i)}$  являются членами скалярного произведения вектора меток с one-hot encoding и вектора предсказания модели,  $c^{(i)}$  - достоверность предсказания (fig. 4b).

### 3.2 N-loss

Поскольку бинарную классификацию можно рассматривать как частный случай многоклассовой классификации, в этом разделе бинарная классификация пропущена.

**Мультиклассовая классификация.** Рассмотрим  $i$ -th сэмпл и модель с логитами  $\mathbf{z}^{(i)} = [\mathbf{z}_{mean}^{(i)}, \mathbf{z}_{var}^{(i)}]$ , которая сопоставляет параметры многомерного нормального распределения: гипотеза или среднее  $\mathbf{h}^{(i)} = \mathbf{z}_{mean}^{(i)}$ , которая аппроксимирует ground truth  $\mathbf{y}^{(i)}$ , и дисперсия  $\sigma_{(i)}^2 = \exp(\mathbf{z}_{var}^{(i)})$ , характеризующая неопределенность гипотезы,  $f[\mathbf{x}^{(i)}, \mathbf{w}] = [\mathbf{h}^{(i)}, \sigma_{(i)}^2]$ . Другими словами, предполагается, что условное распределение вероятностей  $p = p(\mathbf{y}^{(i)} | \mathbf{x}^{(i)}) = p(\mathbf{y}^{(i)} | \mathbf{f}[\mathbf{x}^{(i)}, \mathbf{w}])$  имеет вид многомерного нормального распределения, характеризующегося равными дисперсиями (сферическими ковариациями) в  $N$ -мерном пространстве [17]:

$$p^{(i)} = \frac{\exp \left( -\frac{\sum_{k=1}^N (y_k^{(i)} - h_k^{(i)})^2}{2\sigma_{(i)}^2} \right)}{(2\pi\sigma_{(i)}^2)^{\frac{N}{2}}}, \quad (8)$$

Многомерное нормальное распределение (8) может быть применено к критерию negative log-likelihood с использованием uncertainty-aware negative log-likelihood loss (N-loss) для регрессии [18]:

$$\mathcal{L}_N = \frac{1}{2m} \sum_{i=1}^m \left( \sum_{k=1}^N \frac{(y_k^{(i)} - h_k^{(i)})^2}{\sigma_{(i)}^2} + N(s^{(i)} + r) \right), \quad (9)$$

где  $m$  - число сэмплов (в батче),  $\mathbf{y}^{(i)}$ ,  $s^{(i)} = \log \sigma_{(i)}^2$  - логарифмическая дисперсия,  $r = \log 2\pi$  - константа.

Последнее слагаемое в (9) представляет собой константу, которой можно пренебречь. Кендалл и другие в [11] рекомендуют обучать модели прогнозированию логарифмических отклонений  $s^{(i)} = \log \sigma_{(i)}^2$ , потому что она более стабильна численно, чем дисперсия  $\sigma_{(i)}^2$  и позволяет избежать потенциального деления на ноль в loss-функции:

$$\mathcal{L}_N = \frac{1}{m} \sum_{i=1}^m \left( e^{-s^{(i)}} \sum_{k=1}^N (y_k^{(i)} - h_k^{(i)})^2 + Ns^{(i)} \right). \quad (10)$$

Таким образом, (10) представляет собой гетероскедастическую регрессионную потерю [18, 11], обобщенный для случая пространства из  $N$  измерений. Наше предложение состоит в том, чтобы использовать эту loss-функцию для задач классификации.

Стандартной loss-функцией в задаче мультиклассовой классификации является cross-entropy loss [6, 18, 2]:

$$L_{CE} = -\frac{1}{m} \sum_{i=1}^m \sum_{k=1}^N y_k^{(i)} \log h_k^{(i)}. \quad (11)$$




Рис. 2: Ансамбль моделей  $q$  делает предсказание  $h$  для  $q$  аугментированной копии входного сэмпла  $x$ . Продемонстрирована классификация на два класса.

### 3.3 Ансамблирование

Множество  $q$  моделей  $f_1, f_2, \dots, f_q$  при разной случайной инициализации веса обучаются с одним и тем же набором данных. Такое агрегирование сокращает переобучение и обеспечивает более надежные оценки за счет усреднения отдельных ошибок модели. [1]. Каждая  $j^{\text{th}}$  модель предсказывает индекс класса для данного  $i^{\text{th}}$  входа:

$$\hat{y}^{(i,j)} = \arg \max_k h_k^{(i,j)}, \quad (12)$$

где  $i, j, k$  - индексы, которые ссылаются на  $j^{\text{th}}$  аугментированную версию  $i^{\text{th}}$  сэмпла, и  $k^{\text{th}}$  - компонент вектора предсказания или индекса класса,  $i \in (1, m), j \in (1, q), k \in (0, N - 1)$ .

Окончательный предсказанный класс ансамбля определяется *голосованием большинства*, основанном на предсказании каждой индивидуальной модели  $j^{\text{th}}$ .

$$\hat{y}^{(i)} = \text{mode}(\hat{y}^{(i,1)}, \hat{y}^{(i,2)}, \dots, \hat{y}^{(i,q)}). \quad (13)$$

Окончательный предсказанный класс ансамбля также может быть определён с помощью *взвешенных прогнозы, основанных на достоверности* (см. fig. 2). Каждая модель предсказывает класс  $\hat{y}^{(i,j)}$  и обеспечивает значение доверия  $co^{(i,j)}$  для этого предсказания:

$$co^{(i,j)} = \max_k (h_k^{(i,j)}). \quad (14)$$

Совокупная достоверность для класса  $k$ :

$$co_k^{(i)} = \sum_{j=1}^q co^{(i,j)} \cdot \mathbb{I}(\hat{y}^{(i,j)} = k), \quad (15)$$

где  $\mathbb{I}(\cdot)$  - это функция индикатора, которая возвращает 1 если условие истинно и 0 в остальных случаях,  $co_k^{(i)}$  это суммарная уверенность в классе  $k$  среди всех моделей.

Окончательный прогнозируемый класс:

$$\hat{y}^{(i)} = \arg \max_k co_k^{(i)}. \quad (16)$$

Оценка неопределенности в глубоком ансамблировании выводится из дисперсии прогнозов отдельных моделей. Более высокая дисперсия между выходными данными моделей указывает на большую неопределенность, обеспечивая меру эпистемологической неопределенности.

### 3.4 Метрики

Стандартными показателями классификации для сбалансированных наборов данных являются точность (accuracy), receiver operating characteristic - area under curve (ROC-AUC) [2, 6]. Набор более специфичных показателей, используемых при количественной оценке неопределенности, включает оценку достоверности (см. eq. (14)) [15]: Brier score, энтропия, ожидаемая ошибка калибровки (ECE), negative log-likelihood (NLL), prediction interval coverage probability (PICP), резкость, и другие [16, 7, 5, 9].

Поскольку предлагаемая В-модель (см. eq. (7)) и N-модель (см. eq. (10)) имеют дополнительный выход, могут быть соблюдены следующие дополнительные показатели достоверности:

- $c^{(i)} \in (0, 1)$  для В-модели ;
- $1 - \text{sigm}(s^{(i)}) \in (0, 1)$  для N-модели.

Обе вышеперечисленные метрики могут быть использованы в качестве весов в eq. (16), таким образом, взвешенные прогнозы, основанные на достоверности, должны быть выполнены.

Таблица 1: Аккуратность (%) моделей, обученных на датасете CIFAR-10N с чистыми и зашумленными метками, а также со сглаживанием меток (LS). Каждая модель была обучена с использованием семи различных начальных значений сида в течение 20 эпох, затем объединена в ансамбль. Средняя точность тестирования отдельных моделей сравнивается с точностью ансамбля с использованием голосования большинства (EMV). Наилучшие результаты выделены жирным шрифтом.

Метод	Арх-ра	#Пар-ры. (тренировочные пары)	LS	Accuracy (single model / EMV)%	
				Чистые	Шумные
Baseline CE loss	9-l.CNN	4.4 M (all)	0.0	83.87 $\pm$ 0.006/87.41	71.55 $\pm$ 0.008/74.57
Proposed B-loss				84.24 $\pm$ 0.002/87.78	<b>72.62 <math>\pm</math> 0.01/77.01</b>
Proposed N-loss				<b>86.09 <math>\pm</math> 0.005/89.15</b>	72.48 $\pm$ 0.005/75.72

## 4 Результаты и обсуждение

Датасет CIFAR-10N [25] был разделен на обучающий, валидационный и тестовый наборы в количестве [45000, 5000, 10000] сэмплов, соответственно. Модели были обучены с помощью 9-слойной сверточной нейронной сети [8, 26]. Сеть имеет 4,4 миллиона параметров, которые были случайным образом инициализированы во время обучения. Архитектура CNN и большинство настроек соответствуют экспериментам Xia et al. [26] с небольшими изменениями: модели обучались в течение 20 эпох (200 в оригинальной статье) с использованием оптимизатора Adam с импульсом 0.9, размером батча 128 и с постоянной скоростью обучения 0.001 (в оригинальной работе начальная скорость обучения линейно снижалась до нуля, начиная с 80<sup>th</sup> эпохи); образцы изображений были преобразованы в тензоры и нормализованы с помощью средних значений [0.491, 0.482, 0.447] и стандартных отклонений [0.247, 0.243, 0.261].

Некоторые экспериментальные настройки могут отличаться от настроек в статье [26]: была применена техника построения модельного ансамбля; обрезка произвольного размера в диапазоне масштаба [0.8, 0.1] и в диапазоне соотношений сторон [0.9, 1.1] была применена ко всем сэмплам во всех наборах в качестве преобразования, таким образом, выборка тестового набора была реализована с использованием увеличения времени тестирования с обрезкой произвольного размера; для вывода были использованы модели с наименьшим валидационным потерей.

Все эксперименты проводились семь раз со случайными сидами [42, 0, 17, 9, 3, 16, 2]. Затем были представлены среднее значение и стандартное отклонение результатов эксперимента. Множественные прогнозы, полученные с помощью объединения моделей, позволили рассчитать окончательные прогнозы с использованием голосования большинства.

Аккуратность была использована [12] как метрика. Полученные результаты не сравнивались с результатами, полученными по последнему слову техники. Последние объединяют множество методов и сложные сетевые архитектуры. Таким образом, сравнение было бы несправедливым.

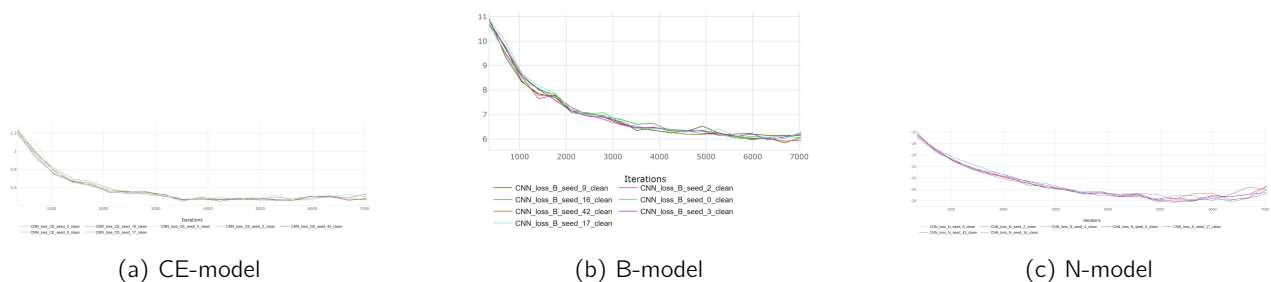



Рис. 3: Значения валидационного потерей во время обучения ансамбля моделей за 20 эпох на чистых данных: CE-model (a), B-model (b), and N-model (c).


Как видно из графиков, лучшие результаты показывают модели на N-loss с чистыми данными и с B-loss на зашумленных данных.

## 5 Этика

LLM-модели использовались в основном для перевода текста как задания, так и сопутствующих статей, а также для небольших правок latex файла.



(a) CE-model



(b) B-model

(c) N-model

Рис. 4: Значения валидационного лосса во время обучения ансамбля моделей за 20 эпох на зашумлённых данных: CE-model (a), B-model (b) (отсутствует из-за ошибки ClearML), and N-model (c).

## 6 Заключение

В данной работе мы исследовали проблему обучения моделей компьютерного зрения на данных с шумными метками, используя датасет CIFAR-10N, который содержит как чистые, так и зашумленные аннотации, основанные на реальных человеческих ошибках. Были рассмотрены архитектура CNN, а также затронуты теоретически ResNet50 и ViT, и три функции потерь: кросс-энтропия (CE-loss), бинарная кросс-энтропия (B-loss) и N-loss, что позволило провести всесторонний анализ устойчивости моделей к шуму. Результаты показали, что зашумленные данные значительно снижают точность моделей.

Проблема шумных меток является одной из ключевых в машинном обучении, особенно в условиях, когда данные размечаются людьми или автоматическими системами, подверженными ошибкам. Наше исследование подчеркивает, что методы, разработанные для искусственного шума, не всегда эффективны на реальных данных, таких как CIFAR-10N. Это указывает на необходимость разработки более гибких и адаптивных подходов, которые учитывают сложную природу шума в реальных условиях.

Одним из ключевых выводов работы является то, что шум в данных не является однородным. Например, классы с визуально схожими признаками (такие как "кошка" и "собака") имеют более высокий уровень шума, что требует разработки методов, способных учитывать контекст и семантику данных. Это открывает новые возможности для исследований в области semi-supervised обучения и методов, основанных на самообучении, где модель может самостоятельно корректировать ошибки в метках.

Хотя наша работа не решает глобальных проблем, она вносит вклад в развитие нечувствительных методов машинного обучения, которые могут быть применены в реальных задачах, таких как медицинская диагностика, автономные транспортные средства и анализ спутниковых изображений. Устойчивые к шуму модели способны повысить надежность и безопасность таких систем, что в конечном итоге может улучшить качество жизни людей.

## Список литературы

- [1] A. Ashukha, A. Lyzhov, D. Molchanov, and D. Vetrov. Pitfalls of in-domain uncertainty estimation and ensembling in deep learning. *arXiv preprint arXiv:2002.06470*, 2020.
- [2] C. M. Bishop and N. M. Nasrabadi. *Pattern recognition and machine learning*, volume 4. Springer, 2006.
- [3] M. Collier, B. Mustafa, E. Kokiopoulou, R. Jenatton, and J. Berent. A simple probabilistic method for deep classification under input-dependent label noise. *arXiv preprint arXiv:2003.06778*, 2020.
- [4] E. Engleson, A. Mehrpanah, and H. Azizpour. Logistic-normal likelihoods for heteroscedastic label noise, 2023.
- [5] T. Gneiting and A. E. Raftery. Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477):359–378, 2007.
- [6] I. Goodfellow, Y. Bengio, and A. Courville. *Deep Learning*. MIT Press, 2016. <http://www.deeplearningbook.org>.
- [7] C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger. On calibration of modern neural networks. *International Conference on Machine Learning*, pages 1321–1330, 2017.
- [8] B. Han, Q. Yao, X. Yu, G. Niu, M. Xu, W. Hu, I. Tsang, and M. Sugiyama. Co-teaching: Robust training of deep neural networks with extremely noisy labels, 2018.
- [9] F. Hernandez, L. Bertino, G. Brassington, E. Chassignet, J. Cummings, F. Davidson, M. Drevillon, G. Garric, M. Kamachi, J. M. Lellouche, et al. Probabilistic forecasting in meteorology: A review. *Quarterly Journal of the Royal Meteorological Society*, 141(688):318–350, 2015.

- [10] L. Hui and M. Belkin. Evaluation of neural architectures trained with square loss vs cross-entropy in classification tasks, 2021.
- [11] A. Kendall and Y. Gal. What uncertainties do we need in bayesian deep learning for computer vision? *Advances in neural information processing systems*, 30, 2017.
- [12] A. Kumar, P. Liang, and T. Ma. Verified uncertainty calibration, 2020.
- [13] E. Mintun, A. Kirillov, and S. Xie. On interaction between augmentations and corruptions in natural corruption robustness, 2021.
- [14] D. Molchanov, A. Lyzhov, Y. Molchanova, A. Ashukha, and D. Vetrov. Greedy policy search: A simple baseline for learnable test-time augmentation, 2020.
- [15] T. Pearce, A. Brintrup, and J. Zhu. Understanding softmax confidence and uncertainty. *CoRR*, abs/2106.04972, 2021. URL <https://arxiv.org/abs/2106.04972>.
- [16] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and E. Duchesnay. Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.
- [17] S. Prince. *Computer Vision: Models Learning and Inference*. Cambridge University Press, 2012.
- [18] S. J. Prince. *Understanding Deep Learning*. MIT Press, 2023. URL <http://udlbook.com>.
- [19] S.-A. Rebuffi, S. Gowal, D. A. Calian, F. Stimberg, O. Wiles, and T. A. Mann. Data augmentation can improve robustness. *Advances in Neural Information Processing Systems*, 34:29935–29948, 2021.
- [20] M. Seitzer, A. Tavakoli, D. Antic, and G. Martius. On the pitfalls of heteroscedastic uncertainty estimation with probabilistic neural networks. *arXiv preprint arXiv:2203.09168*, 2022.
- [21] M. Sensoy, L. Kaplan, and M. Kandemir. Evidential deep learning to quantify classification uncertainty, 2018.
- [22] H. Song, M. Kim, D. Park, Y. Shin, and J.-G. Lee. Learning from noisy labels with deep neural networks: A survey, 2022.
- [23] J. van Amersfoort, L. Smith, Y. W. Teh, and Y. Gal. Simple and scalable epistemic uncertainty estimation using a single deep deterministic neural network. *CoRR*, abs/2003.02037, 2020. URL <https://arxiv.org/abs/2003.02037>.
- [24] J. Wei, H. Liu, T. Liu, G. Niu, M. Sugiyama, and Y. Liu. To smooth or not? when label smoothing meets noisy labels. *arXiv preprint arXiv:2106.04149*, 2021.
- [25] J. Wei, Z. Zhu, H. Cheng, T. Liu, G. Niu, and Y. Liu. Learning with noisy labels revisited: A study using real-world human annotations, 2022. URL <https://arxiv.org/abs/2110.12088>.
- [26] X. Xia, T. Liu, B. Han, M. Gong, J. Yu, G. Niu, and M. Sugiyama. Sample selection with uncertainty of losses for learning with noisy labels, 2021.
- [27] Q. Yao, H. Yang, B. Han, G. Niu, and J. Kwok. Searching to exploit memorization effect in learning from corrupted labels, 2020.